

Assignment 2: LIBSVM Practice

此次作業在於讓同學們練習如何使用 LIBSVM 訓練分類模型。你需要撰寫程式來處理輸入資料與整理輸出結果，以完成此次作業。

本次作業使用的資料庫格式為 SQLite：

- pokemon.db：寶可夢對戰資料庫。
 - pokemon table
 - 1) #: 編號
 - 2) Name: 寶可夢名字
 - 3) Type1, Type2: 寶可夢屬性 (Type2 可能為空值)
 - 4) HP: 血量
 - 5) Attack: 攻擊力 (物理攻擊)
 - 6) Defense: 防禦力
 - 7) Sp. Atk: 特攻攻擊力 (特殊攻擊)
 - 8) Sp. Def: 特防
 - 9) Speed: 速度
 - 10) Generation: 寶可夢版本
 - 11) Legendary: 是否為傳說寶可夢
 - combats table
 - 1) First_pokemon
 - 2) Second_pokemon
 - 3) Winner

LIBSVM input 的檔案格式請參考上課投影片。另外，請將作業轉成 PDF 格式連同最後一題的程式碼檔案上傳至 ilearning 作業二繳交區。

Binary Classification using Pokemon Database (Combat Winner Prediction)

Question 1. (20%) 請從寶可夢資料庫中，先分析各個 attribute，決定哪些可能是重要的特徵值。例如，你可以觀察寶可夢屬性的分布、單一屬性與雙屬性的影響，以及各項數值型屬性（如 HP、Attack、Defense 等）的平均值與標準差，藉此判斷哪些因素可能會對對戰結果造成影響，也可透過例如對戰的初始血量差距或其他的方法建立新的特徵值。請敘述你使用的分析方法，並說明你為什麼認為某些屬性值較重要。

Question 2. (30%) Hold-out

請將對戰資料的 80% 作為 training set、20% 作為 test set。資料分割方式不限 (例如 random sampling 或依資料順序切分)，但需注意 class imbalance 的問題。請至少嘗試五種不同的參數組合，並透過比較以下 evaluation metrics 來選擇你嘗試的參數組合裡面最佳的參數: Confusion Matrix, Accuracy, Precision, Recall (TPR), FPR, TNR 與 FNR，接著請具體說明：參數選擇的過程與依據以及每組參數訓練後模型的 confusion matrix 與各項 evaluation metrics 的數值

Question 3. (30%) Cross-validation

請將上一題的 training set 分成五個等份，並進行 5-fold cross validation。請沿用上一題中所使用的五種參數組合，分別對每一組參數進行一次完整的 5-fold cross validation。因此對於每一組參數（例如 A），會得到五個模型 ($M_{A1}, M_{A2}, M_{A3}, M_{A4}, M_{A5}$)，接著在評估此參數時：

- confusion matrix: 將五個 fold 的結果加總
- 其他 metrics (Accuracy、Precision、Recall 等): 取平均值

請比較不同參數組合的表現並選擇最佳參數並列出每組參數在 validation 上的結果 (confusion matrix 與各項 metrics)。最後，請使用最佳參數在整個 training set 上重新訓練模型，在 test set 上進行評估，並列出此模型的 confusion matrix 與各項 evaluation metrics 的數值。

Question 4. (20%) ROC Curve and AUC

請使用 LIBSVM 的 `-b` (probability estimation) 選項，重新訓練前述任一模型，以取得每筆測試資料的預測機率。請自行撰寫程式：繪製 ROC curve 以及計算 AUC。(不可使用現成套件直接產生 ROC curve 或 AUC，例如 scikit-learn) 請在作業內敘述你如何繪製 ROC curve、計算 AUC 數值跟程式跑完的結果 (ROC curve 圖片)，並附上程式碼的檔案。